封面图替换

目录

第一章 绪论 **3**

1.1 项目背景 3

1.2 图像分类技术概述 3

1.3 眼底疾病识别研究现状 5

1.3.1 国内外研究成果 5

1.3.2 多疾病分类面临的挑战与突破方向 6

1.4 目前存在的问题 7

1.4.1 数据集缺陷 7

1.4.2 模态缺失 7

1.4.3 传统卷积或注意力模型缺陷 7

1.5 主要研究内容 8

1.6 特色综述 9

第二章 解决方案与核心技术 **10**

2.1 解决方案与技术路线 10

2.2 数据集处理 11

2.3 模型设计 13

2.3.1 基于 Mambavision 的图编码 14

2.3.1.1 基于卷积模型的轻量化特征提取层 14

2.3.1.2 基于状态空间模型与多头自注意力机制模块 15

2.3.2 基于 TabTransformer 的表格特征编码 17

2.3.2.1 自注意力机制 18

2.3.2.2 表格特征建模 19

2.3.3 基于 MLP 的多模态融合方法 19

2.4 智能眼底诊断平台设计与实现 20

2.5 实验与分析 22

2.5.1 对比模型 22

2.5.2 指标分析 22

2.5.3 结果分析 23

第三章 项目管理与人员架构 **24**

3.1 人员架构 24

3.2 任务分配与进度安排 24

3.2.1 项目生命周期与组织 25
3.2.2 项目过程管理与质量评估 26
3.2.3 项目风险分析 26
3.2.4 项目评审 27

第四章 可行性分析 **27**
4.1 经济可行性 27
4.2 社会可行性 28
4.3 政策可行性 28
4.4 人员可行性 29
4.5 法律可行性 29

第五章 结语 **30**

第一章　绪论

1.1　项目背景

近年来，受卫生水平提升等因素影响，我国眼病的疾病谱也在发生变化，主要致盲性眼病由以沙眼为主的传染性疾病转变为代谢性、慢性、年龄相关性眼病。随着手术的普及，白内障的致盲率下降，而糖尿病视网膜病变、老年黄斑变性等眼底病的发病率和致盲率不容忽视。

我国眼底疾病患者数量已超 4000 万，其中糖尿病视网膜病变（DR）、老年黄斑变性（AMD）及高度近视性眼底病变是主要致盲因素。2024 年《五百万体检人群健康蓝皮书》显示，77.4% 的体检人群存在眼底异常，40 岁以上人群异常率超过 90%，致盲风险检出率达 1.1%。此外，糖尿病患者的 DR 患病率超过 30%，高血压患者中 70% 伴有眼底病变，凸显慢性病与眼健康的强关联。

眼底疾病患者数量如此庞大，但早期诊断率较低，治疗窗口期短，导致大量患者面临失明风险。“眼底一张照，慢病早知道。”通过一张眼底照片，能了解眼底血管、神经的状况，不但能筛查出常见的致盲眼病，还能发现一些与慢病相关的早期眼部并发症。早诊早治不仅能提升眼底疾病的治疗效果，也能大大减轻费用负担。

我国眼科医生仅 3.5 万人，其中眼底专科医生不足 4000 人，基层医疗机构设备及诊疗能力薄弱，导致正确治疗率不足 20%，患者从确诊到治疗的平均等待时间长达两周至一个月。传统眼底检查依赖高成本设备和专业医师经验，难以覆盖广泛人群。随着人工智能技术的发展，眼底病筛查的可及性与准确性已大幅提升，我国正探索通过基层筛查、转诊模式优化与卫生经济学评估，探索适合我国国情的眼底病管理模式。

本文主要就赛题【A07】赛题“基于眼底医学影像的眼科疾病智能诊断系统”展开研究，通过设计基于卷积神经网络的多种眼底疾病多标签自动分类系统，来实现更高效且精确的眼科疾病识别问题，通过数据清洗，标签平衡，图像增强的操作，使用多模态融合模型 **MambaFusion** 为核心的技术框架，通过轻量化预处理、跨模态特征对齐与高效推理架构，构建从数据到诊断的完整闭环。本研究还可扩展运用于其他医学影像领域，如 CT、X 光图像分析等，进一步提升智能诊断系统的通用性和应用范围。

1.2　图像分类技术概述

图像分类是计算机视觉中的重要任务，广泛应用于医学影像，如 X 光、CT、MRI 等。随着医学影像数量的增加，传统机器学习方法（如 SVM、LR、RF）由于需手动提取特征而面临性能瓶颈。深度学习，特别是卷积神经网络（CNN），通过自动特征提取，在医学图像分类中表现出巨大潜力。

CNN 通过卷积层提取局部特征，池化层进行下采样，全连接层进行分类。2012 年，Alex Krizhevsky 等人提出 AlexNet[1]在 ImageNet 大规模视觉识别挑战赛中取得了惊人的成绩。VGG 是由 Karen Simonyan 和 Andrew Zisserman 于 2014 年提出的卷积神经网络模型[2]，VGG 网络采用了重复堆叠的小卷积核和池化层，构建了 16 或 19 层的深度网络结构。ResNet 是由 Microsoft Research 团队于 2015 年提出的一种深度残差网络模型[3]，通过引入跳跃连接和残差学习的思想，成功解决了深层网络训练过程中的梯度消失和网络退化问题。ResNet 的结构简单而有效，极大地加深了网络的深度。DenseNet 是由 Gao Huang 等人于 2016 年提出的一种稠密连接的卷积神经网络模型[4]，它通过将每一层的特征图与之前所有层的特征图进行连接，实现了特征的复用和信息的流动。DenseNet 具有更少的参数量和更高的参数利用率，使得网络训练更加高效和稳定。谷歌提出的 MobileNet[5]和 Mingxing Tan 等提出的 EfficientNet[6]等轻量级网络减少了模型的参数量和计算量，使得移动终端、嵌入式设备运行神经网络模型成为可能。

另一方面，transformer 已成为执行自然语言处理（NLP）任务的首选模型。transformer 具有可扩展性，计算效率高，能够建立大量参数训练模型，而不会使模型性能饱和。受到应用于 NLP 的转换器成功的启发，并假设自我注意机制也可用于图像分类任务，Vision Transformers（ViT）的架构被提出[7]。它包括将图像拆分成块，并将这些图像块的线性嵌入序列作为 Transformer 的输入。当拥有足够多的数据进行预训练的时候，ViT 的表现就会超过 CNN。然而由于 Transformer 和 CNN 相比缺少归纳偏置，在数据量不够大时，ViT 的表现通常比同等大小的 ResNets 要差一些。华中科技大学、地平线、智源人工智能研究院等机构使用的 Vision Mamba 通过为图像序列添加位置嵌入[8]，并利用双向选择性状

[1]Krizhevsky, A. , Sutskever, I. , & Hinton, G. . 2012. ImageNet Classification with Deep Convolutional Neural Networks. NIPS Vol.25. Curran Associates Inc.

[2]Simonyan, K., & Zisserman, A. (2014). Very Deep Convolutional Networks for Large-Scale Image Recognition. CoRR, abs/1409.1556.

[3]He, K., Zhang, X., Ren, S., & Sun, J. (2015). Deep Residual Learning for Image Recognition. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770-778.

[4]Huang, G., Liu, Z., & Weinberger, K.Q. (2016). Densely Connected Convolutional Networks. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2261-2269.

[5]Howard, A.G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. ArXiv, abs/1704.04861.

[6]Tan, M., & Le, Q.V. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. ArXiv, abs/1905.11946.

[7]Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2020). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ArXiv, abs/2010.11929.

[8]Zhu, L., Liao, B., Zhang, Q., Wang, X., Liu, W., & Wang, X. (2024). Vision Mamba: Efficient Visual Repre-

态空间模型（SSM）压缩视觉表示，以序列方式处理图像。

医学图像与自然图像的不同之处在于，它们通常包含许多不相关的区域和伪影。因此，有必要进行预处理以提高图像质量、突出关键特征、降低噪声并满足模型输入要求。这旨在提高模型的特征提取效果、泛化和鲁棒性。对于视网膜图像，最常见的预处理方法包括去噪、归一化、直方图均衡化、分割等。

1.3 眼底疾病识别研究现状

1.3.1 国内外研究成果

眼底照片用于眼科疾病识别是近年来人工智能领域的重要研究方向，很多国内外的团队都在致力于这一领域，尤其是在糖尿病视网膜病变（DR）、青光眼、黄斑变性、视网膜病变等眼科疾病的早期检测和诊断上取得了一些显著成果。

多视觉语言模型与文本增强: 2024 年提出的基于对比语言图像预训练（CLIP）的多标签识别算法，通过 GPT-4 生成眼底图像的细粒度病理文本描述（如“黄斑区硬性渗出物分布”或“视盘边缘模糊”），解决了传统数据集中标签稀疏的问题[9]。该方法在 MDFCD8 数据集（包含 8 类疾病）上的平均精度（AP）达 0.912，较传统 CNN 和 Transformer 分别提升 4.8% 和 3.2%。

多标签联合学习网络: 中山大学林浩添团队开发的 CARE 系统采用单一卷积神经网络（CNN）结构，共享不同疾病的特征信息，并通过多标签联合训练提升模型泛化能力。该模型在识别 14 种眼底疾病时，平均 AUC 从传统单病种模型的 0.921 提升至 0.952，尤其对黄斑裂孔的识别 AUC 从 0.786 跃升至 0.953[10]。

多模态成像技术与算法协同: 光学相干断层扫描技术 (OCT) 提供高分辨率视网膜断层图像，AI 模型可结合 OCT 与眼底彩照进行多模态分析[11]。例如，黄斑水肿的识别通过 OCT 厚度测量与彩照渗出物检测联合判断，准确率提升至 97%. 自适应光学成像（AO）通

---

sentation Learning with Bidirectional State Space Model. ArXiv, abs/2401.09417.

[9]XIONG Shaokui, CHEN Shifeng.Multi-disease Recognition Method for Fundus Images Based on Text Enhancement[J].Journal of Integration Technology,2025,14(1):78-90

[10]Lin D, Xiong J, Liu C, Zhao L, Li Z, Yu S, Wu X, Ge Z, Hu X, Wang B, Fu M, Zhao X, Wang X, Zhu Y, Chen C, Li T, Li Y, Wei W, Zhao M, Li J, Xu F, Ding L, Tan G, Xiang Y, Hu Y, Zhang P, Han Y, Li JO, Wei L, Zhu P, Liu Y, Chen W, Ting DSW, Wong TY, Chen Y, Lin H. Application of Comprehensive Artificial intelligence Retinal Expert (CARE) system: a national real-world evidence study. Lancet Digit Health. 2021 Aug;3(8):e486-e495. doi: 10.1016/S2589-7500(21)00086-8. PMID: 34325853.

[11]Li F, Wang D, Yang Z, Zhang Y, Jiang J, Liu X, Kong K, Zhou F, Tham CC, Medeiros F, Han Y, Grzybowski A, Zangwill LM, Lam DSC, Zhang X. The AI revolution in glaucoma: Bridging challenges with opportunities. Prog Retin Eye Res. 2024 Nov;103:101291. doi: 10.1016/j.preteyeres.2024.101291. Epub 2024 Aug 24. PMID: 39186968.

过校正眼球像差，捕捉微血管异常等早期病变。研究显示，AI 结合 AO 图像可将青光眼视神经病变的早期诊断灵敏度从 75% 提升至 92%. 超广角眼底成像（UWFI）：武汉大学团队利用 UWFI 覆盖视网膜周边区域，其模型对周边视网膜脱离的识别准确率达 94.07%，填补了传统后极部成像的盲区.

大规模验证与临床应用**:** 中山大学团队使用超过 26 万张眼底图像（覆盖中国 28 个省市、51 家医疗机构）训练 CARE 系统，并在 35 家医疗机构进行前瞻性验证。结果显示，CARE 在真实世界中的平均 AUC 为 0.968，与眼底病专家表现相当，且对不同种族（如拉丁美洲人群）和相机型号（包括老式胶片扫描图像）的适应性强（AUC 仍保持 0.88 以上）。

当前眼科 AI 技术通过多模态数据融合、多标签联合学习及生成式文本增强，实现了疾病识别的精准化与高效化：基于 CLIP 的文本增强模型突破标签稀疏瓶颈，多模态成像技术（如 OCT 与 AO）显著提升早期病变检出率，而 CARE 系统等联合学习框架在复杂多病种诊断中展现了临床级性能。大规模验证进一步证实其跨种族、跨设备的强鲁棒性，标志着眼科 AI 从实验室迈入真实世界应用。

未来，技术发展将聚焦三大方向：一是拓展多模态组合（如 OCT+ 血管造影）以覆盖更多罕见病；二是通过轻量化设计推动基层医疗普惠化；三是深度融合生成式 AI，实现从影像分析到报告生成的端到端自动化。这些突破有望重塑眼科诊疗流程，推动疾病防治向智能化、个体化迈进。

1.3.2 多疾病分类面临的挑战与突破方向

目前，已有诸多研究尝试在眼底影像多分类数据集上应用如 VGG[12]、EfficientNet[13]、SENet 等经典的二维卷积神经网络模型，探索多标签分类任务的性能表现。然而，实验结果显示，这些传统架构在多病种共存条件下的表现仍未达到临床可用标准，存在多个技术瓶颈，具体体现在以下几个方面：

跨模态数据融合不足：眼底影像多分类数据集除图像信息外还包含患者的年龄、性别及主观症状描述等非图像信息，但现有模型大多局限于视觉模态，未能充分融合非图像特征，导致疾病辅助判别能力受限。

全局与局部特征解耦不充分：眼底图像中，某些疾病的征兆往往只出现在局部区域（如黄斑区、视盘区），而另一些则需关注整体血管结构或颜色分布。现有模型对图像的全局-局部特征提取缺乏有效的解耦建模，容易造成不同疾病间的特征混淆，影响多标签

[12]Jordi CC, Joan Manuel NDR, Carles VR. Ocular Disease Intelligent Recognition through Deep Learning Architectures. Barcelona, Spain:Universitat Oberta de Catalunya; 2019.

[13]WangJ, Yang L, HuoZ,HeW,LuoJ.Multi-label classification of fundus images with EfficientNet.IEEE Access. 2020;8: 212499–212508.

分类精度。

静态卷积核表达能力有限：传统CNN使用固定参数的卷积核，难以动态适应图像中不同病理特征的分布变化，尤其在处理多种疾病高度共现、边界模糊的复杂场景下，缺乏足够的表达能力和灵活性，导致模型对疾病间语义关联的建模能力不足。

这些问题揭示了当前深度学习模型在特征泛化能力、疾病共现关联推理等关键技术环节上的短板，也反映出从“分类准确率”到“病理可解释性”之间的鸿沟，亟待通过新型网络范式与优化策略实现突破。

1.4 目前存在的问题

1.4.1 数据集缺陷

实验所使用的数据集包含约5000名患者的双眼彩色眼底图像，但该数据集存在以下几个问题：首先，尽管包括了多种疾病的眼底图像，然而这些疾病的类别划分并不细致，导致某些疾病的比例较高，但缺乏详细的标签分类。这一问题可能导致模型在训练过程中对不同病种的学习产生偏倚，尤其是对于罕见病种，模型可能难以捕捉到其特征。

此外，数据集中还存在严重的标签类别不平衡现象，某些常见病种占据了大量的样本，而较为罕见的病种样本量较少。这种不平衡会影响模型的泛化能力，使其在实际应用中对罕见病种的识别能力较弱，导致系统在多标签分类任务中的性能下降。

1.4.2 模态缺失

在过去的研究中，尽管图像信息被广泛应用于疾病诊断中，许多工作忽视了与图像同样重要的非图像数据，如患者的诊断关键字、病史记录及主观症状描述等文本信息。传统的研究大多专注于单一的图像模态，未能充分考虑到多模态数据的融合。

然而，眼科疾病的诊断不仅仅依赖于图像数据，还往往需要结合患者的其他临床信息，如年龄、性别及过往病史等。这些非图像信息可以为疾病的诊断提供更多的背景信息，从而提升诊断的准确性和鲁棒性。忽视这些重要的非图像信息，可能导致模型对疾病的理解不全面，造成一定程度的语义缺失。因此，未来的研究应注重多模态数据的有效融合，以挖掘数据集中的潜在信息，提升模型的综合表现。

1.4.3 传统卷积或注意力模型缺陷

尽管传统的卷积神经网络（CNN）在图像处理领域取得了显著的成功，但其仍存在一些局限性。卷积模型通过局部卷积核逐层提取特征，受限于固定的感受野，难以有效捕捉图像中远距离的依赖关系，尤其是在处理图像中的细粒度特征时，可能会忽略掉一

些分散但语义相关的区域。这使得细粒度分类任务的精度受到影响，尤其是在图像中关键细节丢失的情况下。

卷积网络为了扩大感受野，常常依赖池化操作来提升特征提取的范围，但池化操作同时会带来信息损失，从而降低了模型对细节的敏感度。为了提升卷积模型的性能，常常采用增加网络深度或宽度的方法，但这会导致参数量剧增，进而使得模型变得更加复杂，不仅增加了训练和推理的计算负担，还难以部署到资源受限的设备上。因此，如何平衡性能与计算资源的需求，成为卷积模型的一大挑战。

相比之下，注意力机制在捕捉长距离依赖关系上展现了较大的优势，尤其在自然语言处理和视觉任务中，能够通过自注意力机制更好地聚焦于图像中的重要区域。然而，传统的注意力模型在处理图像时通常将图像划分为序列并进行操作，这导致其计算复杂度为 $O(n^2)$，在处理高分辨率图像时，内存需求激增，可能会导致训练过程中的内存溢出或计算效率低下。另一个问题是，注意力模型中位置编码的固定或随机初始化可能对噪声较为敏感，从而影响模型的鲁棒性和泛化能力。因此，在大规模图像数据处理任务中，如何改进注意力机制的计算效率，并提高其在实际应用中的稳定性，仍是一个值得深入研究的课题。

1.5 主要研究内容

依照目前最新的深度学习图像分类领域的相关研究以及赛题方对模型的预估要求，我们本团队展开了以“基于状态空间建模与多模态融合机制的新型眼底图像分类框架——**MambaFusion** 模型”的研究，该模型通过图像增强与标签平衡策略优化数据质量，并结合长序列建模与跨模态对齐机制，实现对复杂眼底病灶的高效诊断。

为了更好提高分类模型在眼底图像上的分类效果，本团队通过对所用数据集特征进行分析以及对眼底图像领域研究现状的调查，决定先从数据集的预处理入手，以图像特征增强与样本标签平衡作为两大方向：通过基于直方图的自适应均衡化方法与伽马矫正手段，实现图像在亮度与色彩上的平衡；通过补充多标签视网膜分类数据集，辅以重采样技术达成各类疾病标签的平衡化。我们的预处理有效提高了数据集的质量，以便于后续的处理流程。

在此基础上，我们基于多模态的特征分析构建了分类模型，该模型通过综合考虑图像模态与表格模态，实现在眼底疾病样本上的高效诊断：针对图像模态，我们创新性地引入了 MambaVision 这一结构，在提高预测精度的同时极大降低了计算的复杂度，并通过调整平均池化层的改进实现了在我们模型中的有效嵌入；对基于患者信息的表格模态，我们使用了 TabTransformer 这一基于自注意力机制的模型。通过多头自注意力机制实现跨模态编码间的对齐融合，我们的模型实现了在指定数据集上极高的精确率指标。

同时，本团队通过 Nextjs 框架与 Flask 轻量化后端服务，搭建了我们自己的网页应

用，可供医疗从业者或患者上传样本获取诊断结果，完成了本赛题的全部需求。

1.6 特色综述

围绕着本赛题方提供的赛题“基于眼底医学影像的眼科疾病只能诊断系统”，本团队研究了以下四个核心技术点：

1. 自适应眼底图像增强技术的设计与实现

本团队针对眼底图像中常见的过曝与欠曝问题，提出了一种融合型图像增强方法。该方法创新性地结合了对比度受限自适应直方图均衡化（CLAHE）与动态 Gamma 矫正算法。具体地，通过对图像亮度进行分区映射处理，在局部增强对比度的同时，动态调整图像的整体亮度水平，从而有效消除了极端曝光区域。该算法具备良好的自适应性和端到端处理能力，无需人工干预即可自动完成图像增强，显著提升了病灶区域的清晰度和可识别性，为后续疾病识别模型提供了更加高质量的输入数据，解决了眼底医疗图像质量参差不齐的问题。

2. 多标签不平衡数据的重构与样本均衡策略

在眼底图像疾病识别任务中，原始的数据集部分罕见疾病样本数量稀少，导致模型训练偏向多数类，严重影响识别性能。为此，本团队在充分分析原始数据集的基础上，进行了 MULTI-LABEL RETINAL DISEASE 数据集的样本筛选与补充，并构建了包含八类主要眼底疾病的扩展数据集。随后，通过采用过采样与欠采样相结合的重采样策略，重新平衡了各类标签的占比，确保模型能够在训练过程中充分学习各类疾病的判别特征，有效缓解了多标签不平衡带来的性能瓶颈。

3. 状态空间模型驱动的长序列图像建模方法

传统眼底图像识别任务中普遍采用卷积神经网络（CNN）或注意力机制（如 Transformer）来提取图像特征，然而这些方法在处理长距离依赖信息时计算开销大，且感受野存在局限。为此，本团队创新性地将状态空间模型（State Space Model, SSM）引入到医疗影像分析领域，通过建模图像中的长序列依赖关系，在保持甚至拓展全局感受野的前提下，大幅度降低计算资源的消耗。这一方法不仅提升了模型对复杂病灶区域的识别能力，也为医学图像处理中高效建模提供了新的路径。

4. 图像与结构化数据的跨模态融合诊断机制

眼底疾病的诊断不仅依赖图像信息，还涉及患者的结构化表格数据（如年龄，性别）。针对单一模态模型诊断信息不足的问题，本团队设计了一种图像与表格特征的跨模态融合机制。通过在特征层面对多源信息进行对齐与融合，实现了图像模态与结构化数据之间的信息互补与协同推理，从而显著提升了模型的诊断准确性与泛化能力。实验结果显示，该多模态融合模型在多个关键性能指标上均优于单模态基线模型，展现出良好的实际应用前景。

第二章　解决方案与核心技术

2.1　解决方案与技术路线

针对赛题方提出的眼底医学影像分类精度指标以及本团队对目前最新的图像与多模态模型进行调研的结果，本团队设计了一套完整的解决方案。项目的整体解决方案如下图所示：

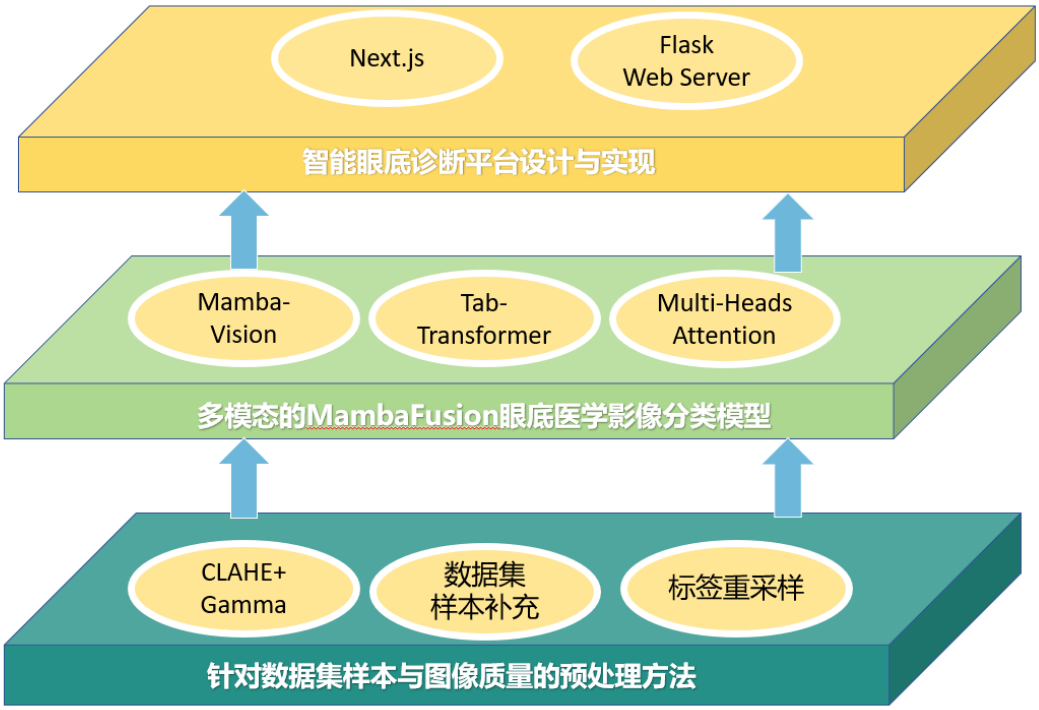

图 1: 项目总体研究方案

该方案主要展开以“多模态的 MambaFusion 眼底医学影像分类模型”为核心内容的研究。

本团队首先通过调研分析，针对数据集标签分布不平衡的现象，引入了其他数据集的样本作为补充，以及使用重采样技术进行调整，而面对图像亮度与色彩不平衡的现象，我们应用了自适应直方图均衡化与伽马校正算法，保证了眼底医学影像的高质量。随后，使用 MambaVision 与 TabTransformer 分别编码图像与表格数据，使用 Multi-heads Attension 与 MLP 进行跨模态间的对齐融合，构建了 MambaFusion 模型。该模型创新性地引入了选择性状态空间模型，有效提高了模型的性能与精度，达到了赛题方的指标。

最后，本团队通过基于 Next.js 与 Flask 的 Web 技术，搭建了眼底医学影像智能诊断平台，完成了赛题方的所有要求。

2.2 数据集处理

在本项目中，我们使用了赛事比赛公开的数据集。该数据集总共提供了 2885 个病例，每个病例包含左右眼底图片，左右眼底图片诊断关键字和总共八个类别的标注。其中八个类别的标注分为正常和七类眼部疾病（糖尿病 (D)、青光眼 (G)、白内障 (C)、年龄相关性黄斑病变 (A)、高血压 (H)、近视 (M)、其他疾病/异常 (O)）。

(1) 数据集清洗

在我们的数据预处理阶段，我们进行了严格的数据清洗工作，以确保模型能够学习到高质量的眼底图像特征。具体来说，我们从原始数据集中去除了以下几类不符合分析要求的样本：（1）视盘（Optic Disc, OD）不可见的图片，（2）有严重反光或色散的图片，（3）非眼底图片，主要为误标样本（如外部眼部图像）。

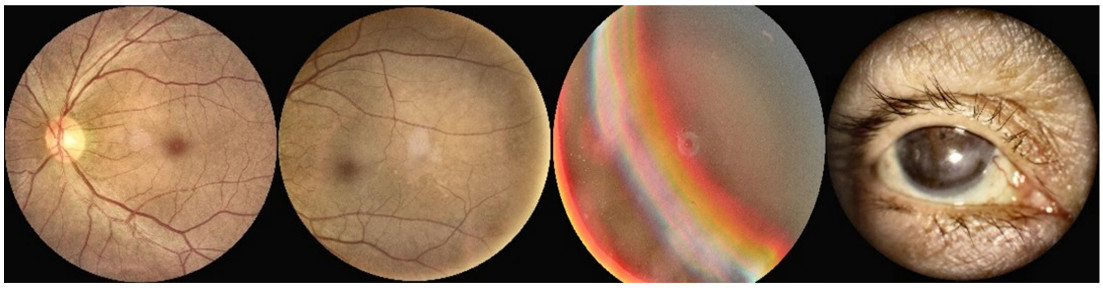

图 2: 原始数据库去除图片示例

(2) 数据集扩充和标签平衡

原始数据集中 8 类疾病标签分布不均衡，特别是青光眼（G）、高度近视（M）和高血压（H）等类别的样本数量明显偏少。这种数据不均衡问题可能导致模型在训练时更倾向于预测常见类别，而忽视罕见类别。因此，我们采取了以下策略来扩充数据集并平衡标签分布。

我们引入了 Ocular Disease Recognition（ODIR）[14] 数据集作为补充，与现有数据集进行比对，选取了不重复的样本加入训练。此外，从 MULTI-LABEL RETINAL DISEASE（MLRD）[15]数据集中筛选了青光眼 (G)、高度近视 (M) 和高血压 (H) 分别选取了数量为 195、72、73 的样本作为扩充。为了使样本进一步平衡，我们采用了过采样技术[16]，对于数量较少的样本，我们对每张图片至多采样两次，确保每个类别的单眼图像至少有 800

[14]Li, N., Li, T., Hu, C., Wang, K., Kang, H. (2021). A Benchmark of Ocular Disease Intelligent Recognition: One Shot for Multi-disease Detection. In: Wolf, F., Gao, W. (eds) Benchmarking, Measuring, and Optimizing. Bench 2020.

[15]Rodriguez Rivera, Manuel Alejandro; Al-Marzouqi, Hasan; Liatsis, Panos (2022), “Multi-Label Retinal Diseases (MuReD) Dataset”, Mendeley Data, V1, doi: 10.17632/pc4mb3h8hz.1

[16]Abdi L, Hashemi S. To combat multi-class imbal anced problems by means of over-sampling and boosting techniques. IEEE Trans Knowl Data Eng. 2015;28(1):238–251.

张。

表 1: 单眼图像的各类别数量

源数据集标签	N	D	G	C	A	H	M	O
源数据集标签数量	2548	722	249	270	334	313	297	763
经过数据集扩充与标签平衡后的数据	2548	800	854	800	836	800	800	800

(3) 图像预处理

首先我们对图像进行了裁切，切除了眼底图像周围的多余黑边。视网膜眼底图像中血管结构的形态、分布、直径和分支特征提供了重要的临床信息，视网膜图像的颜色变化和亮度分布可以揭示不同组织的状态。在图像输入模型进行训练之前，我们通过直方图自适应均衡化和伽马矫正以增强眼底图像，提高模型的特征提取效果。

直方图自适应均衡化

直方图均衡化是一种增强图像对比度的经典方法，其基本思想是将图像的灰度直方图通过累积分布函数（CDF）变换为近似均匀分布，从而增强图像中像素值的对比性，改善图像的可视化效果。该方法尤其适用于图像灰度值集中分布的情况，可以显著提升图像细节。

直方图均衡化的数学表达如下:

$$s_k = \sum_{j=0}^{k} \frac{n_j}{MN}, \quad k = 0, 1, 2, \ldots, L-1$$

其中，s_k 表示灰度级 k 对应的映射后灰度值，n_j 是灰度级 j 的像素数量，$M \times N$ 是图像的总像素数，L 是图像的灰度级总数。

直方图自适应均衡化（**AHE**）

为了解决全局均衡化在图像存在亮度变化时增强效果不理想的问题，AHE（Adaptive Histogram Equalization）算法引入了局部窗口的概念，即在每个图像小区域内分别进行直方图均衡化，适用于改善图像的局部对比度，提取更多细节，尤其在医学图像中具有良好的表现。

AHE 的计算公式与全局直方图均衡化类似，只是将全图像的像素数 MN 替换为局部窗口大小 mn:

$$s_k = \sum_{j=0}^{k} \frac{n_j}{mn}, \quad k = 0, 1, 2, \ldots, L-1$$

其中 mn 表示局部窗口的像素数量，其他符号含义与上式相同。

伽马矫正（**Gamma Correction**）

伽马矫正是一种非线性的图像增强技术，主要用于调整图像的亮度分布，从而提升图像在深色和浅色区域的对比度。该方法利用伽马函数对图像的像素值进行幂次映射，以便更符合人眼对亮度的响应特性。

伽马矫正的表达公式如下：

$$I_{\text{out}} = 255 \times \left(\frac{I_{\text{in}}}{255}\right)^{\gamma}$$

其中，I_{in} 为输入像素值，I_{out} 为经过伽马矫正后的输出值，γ 为亮度控制参数。在本实验中，γ 的取值设定为 0.8，有助于增强图像中暗部的亮度，抑制过曝区域，从而实现更均衡的视觉效果。

结合 AHE 和 Gamma 技术进行混合图像增强，可以在提升图像局部细节的同时，有效调整图像整体亮度分布，特别适用于眼底图像中病灶区域的增强处理。

2.3 模型设计

本文提出的多模态融合模型旨在有效整合图像与表格数据，其整体架构如图 3 所示，主要由三部分组成：基于 Mambavision 的图编码模块、基于 TabTransformer 的表格特征编码模块，以及基于 MLP 的多模态融合层。首先，针对输入的图像特征矩阵 $\mathbf{F_{image}} \in \mathbb{R}^{N\times D}$，图编码模块通过轻量化卷积层实现高效特征提取，并引入状态空间模型与多头自注意力机制联合建模长程依赖关系，结合 TTF Block 优化特征表示。其次，表格特征编码模块采用改进的 TabTransformer 结构，通过堆叠自注意力层捕获表格数据中的复杂关联模式，并构建层次化特征交互。最后，通过多层感知机（MLP）将两类异构特征映射至统一语义空间，输出概率向量 **Probability** $\in \mathbb{R}^8$ 完成多任务预测。各模块设计细节将在后续章节依次展开阐述。

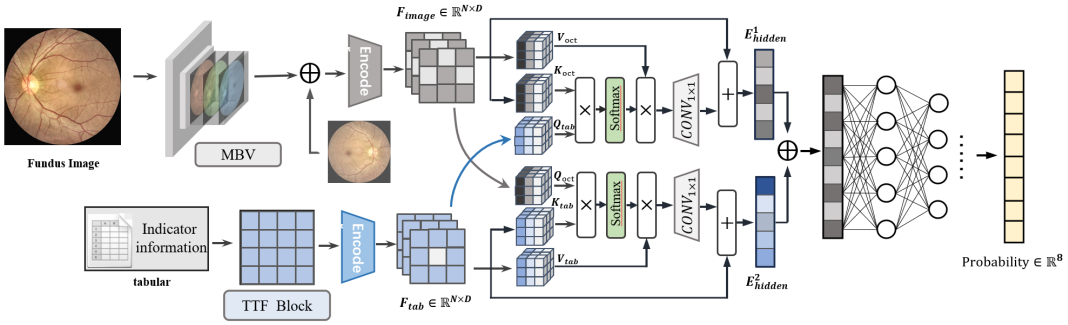

图 3: 总模型设计图

2.3.1 基于 Mambavision 的图编码

在眼底图像分类领域，尽管传统的卷积神经网络（CNN）和视觉 Transformer（ViT）的模型已实现较高的分类精度，但其架构设计仍面临两难困境——CNN 的局部感受野限制了对血管网络拓扑、微动脉瘤等病灶的全局关联建模能力，而 ViT 的二次计算复杂度在分析高分辨率眼底图像时会产生巨大的显存和算力消耗，难以适配移动端医疗设备的实时诊断需求。尤其在实际临床场景中，眼底图像的病理特征往往呈现多尺度分布（如黄斑区水肿的局部渗出与全视网膜血管病变），传统模型往往难以在计算效率和特征捕获广度间取得平衡。

基于深度学习技术的前沿进展与多次实验数据的对比验证，我们创新性地引入了 Mambavision[17]对眼底图像进行编码，为过往诸多模型无法解决的核心矛盾提供了突破性的解决方案：通过分阶段的轻量化的特征提取层次、视觉优化的 Mamba-ssm 模块与后置的 Transformer 全局聚合机制，递进式的处理流程在眼底图像分类的任务中展现出独特的优势。具体而言，该模型由以下层次组成：

Stage1/Stage2：基于 CNN 的轻量化特征提取层

Stage3/Stage4：基于状态空间模型与多头自注意力机制模块

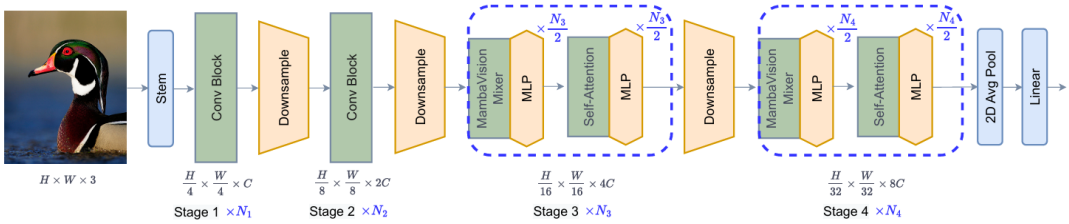

图 4: Mambavision 模型层次图

2.3.1.1 基于卷积模型的轻量化特征提取层

MambaVision 的前两层架构是其分层设计中的基础特征提取模块，专注于高分辨率图像的高效局部特征捕获。该部分通过创新的 CNN 残差块设计与硬件优化策略，为后续的混合模块提供高质量的初级特征表示。

对于一个输入图像 $\mathbf{X} \in \mathbb{R}^{H \times W \times 3}$，首先将其通过重叠的 Patch 划分并转换为嵌入空间，具体形式如下：

$$\mathbf{Z}_0 = \mathrm{Conv}_{3\times3}(\mathbf{X})$$

[17]Hatamizadeh, Ali and Jan Kautz. “MambaVision: A Hybrid Mamba-Transformer Vision Backbone.” ArXiv abs/2407.08083 (2024): n. pag.

其中，卷积操作采用带有重叠的滑动窗口方式（重叠率为 15%），以增强微小病灶区域的连续性特征提取能力。

卷积模块采用如下形式的残差结构进行构建，其中 GELU 和 BN 分别表示高斯误差线性单元激活函数（Gaussian Error Linear Unit）和批归一化（Batch Normalization）操作：

$$\hat{\mathbf{z}} = \mathrm{GELU}\left(\mathrm{BN}\left(\mathrm{Conv}_{3\times3}(\mathbf{z})\right)\right),$$
$$\mathbf{z} = \mathrm{BN}\left(\mathrm{Conv}_{3\times3}(\hat{\mathbf{z}})\right) + \mathbf{z}$$

经过两层卷积模块与下采样操作后，图像的空间分辨率将从 $H \times W$ 降低为 $\frac{H}{8} \times \frac{W}{8}$，通道数扩展为 C，以保证对微小病灶的连续性特征提取。

2.3.1.2 基于状态空间模型与多头自注意力机制模块

传统的视觉模型因二次方计算复杂度面临长序列处理瓶颈，而 Mamba[18]这一改进的结构化状态空间模型的引入为这一困局提供了突破性解法。基于 Mamba 与 Transformer 的混合架构，突破了传统视觉模型在长程依赖与计算效率间的权衡瓶颈，为医疗图像识别乃至整个计算机视觉领域，提供了一种从局部到全部的全新协同范式。

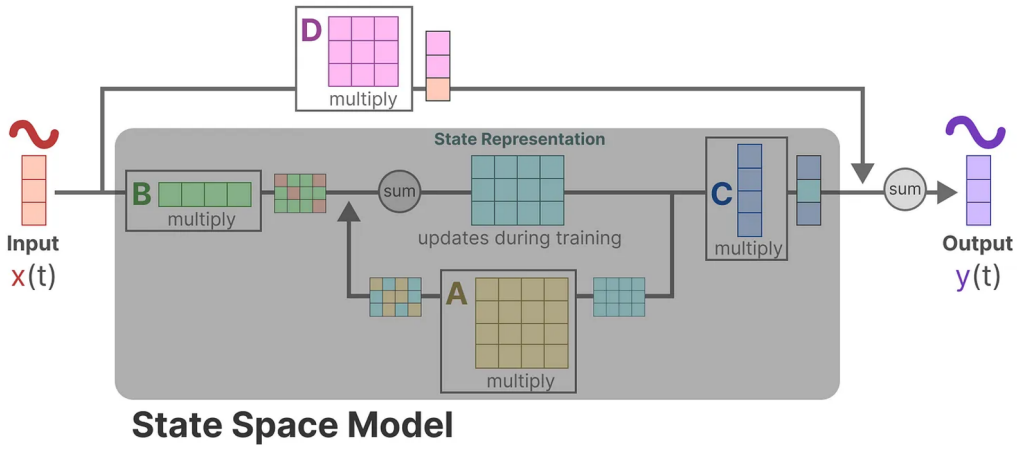

图 5: Mamba 状态空间模型

(1)Mamba 状态空间模型

状态空间模型，即 SSM（State Space Model），是一种通过状态方程和输出方程描述动态系统演变的数学模型，其核心思想是利用隐藏状态传递序列信息，并通过线性投影生成输出。Mamba 是基于选择性状态空间模型改进的序列建模架构，由 Albert Gu 和 Tri Dao 提出。Mamba 通过动态调整模型参数，解决了传统模型在处理长序列时因二次计算复杂度 $O(N^2)$ 导致的效率瓶颈，将复杂度降低至线性 $O(N)$。Mamba 的核心创新在于

[18]Gu, Albert and Tri Dao. “Mamba: Linear-Time Sequence Modeling with Selective State Spaces.” ArXiv abs/2312.00752 (2023): n. pag.

“选择性机制”，能够根据输入内容灵活选择保留或忽略信息，从而提升长文本、基因组数据等任务的推理效率。以下为 SSM 的基本表达式：

$$h'(t) = Ah(t) + Bx(t),$$
$$y(t) = Ch(t)$$

其中，$h(t) \in \mathbb{R}^M$ 为隐藏状态，$x(t) \in \mathbb{R}^M$ 为一维的连续输入信号，$\boldsymbol{A} \in \mathbb{R}^{M\times M}$ 与 $\boldsymbol{B} \in \mathbb{R}^{1\times M}$ 为状态转移矩阵和输入投影矩阵，$y(t) \in \mathbb{R}$ 为模型的输出。

为提高计算的效率，上述的 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$ 连续参数需要转化为离散参数。具体而言，我们可以假设时间步长为 Δ，可以应用零阶保持规则（Zero-Order Hold, ZOH）来获取离散参数：

$$\bar{\boldsymbol{A}} = \exp(\Delta \boldsymbol{A}),$$
$$\bar{\boldsymbol{B}} = (\Delta \boldsymbol{A})^{-1}(\exp(\Delta \boldsymbol{A}) - \boldsymbol{I}) \cdot (\Delta \boldsymbol{B}),$$
$$\bar{\boldsymbol{C}} = \boldsymbol{C},$$

这种离散化方法能够提升计算效率，更便于现实的实现。将上述表达式带入到原方程可得：

$$h(t) = \bar{\boldsymbol{A}}h(t-1) + \bar{\boldsymbol{B}}x(t),$$
$$y(t) = \bar{\boldsymbol{C}}h(t)$$

对于一个大小为 T 的输入序列，可以用带有卷积核 K 的全局卷积进一步简化上式中的输出，具体如下：

$$K = (CB, CAB, \ldots, CA^{T-1}B),$$
$$y = x * K,$$

Mamba 对于传统的状态空间模型做了进一步的改进，引入了一种选择机制，使得模型能够进行依赖于输入的序列处理。这种机制使得模型的参数可以根据输入动态调整，从而滤除无关信息。设输入 $\mathbf{X}$ 是 $\mathbf{T} \times \mathbf{C}$ 矩阵，其中 $\mathbf{T}$ 为序列长度，$\mathbf{C}$ 为嵌入维度，第 3 和第 4 阶段的第 n 层输出可以按如下方式计算：

$$\hat{X}^n = \mathrm{Mixer}(\mathrm{Norm}(X^{n-1})) + X^{n-1},$$

$$X^n = \mathrm{MLP}(\mathrm{Norm}(\hat{X}^n)) + \hat{X}^n,$$

(2) 层架构

经过重新设计的 Mamba 模块将更加适合处理视觉任务：传统的因果卷积（Causal Convolution）将被替换为常规卷积，传统的因果卷积将会限制信息的方向，这对于视觉任务来说是多余不必要的；此外还添加了一个不包含 SSM 的对称分支，由额外的卷积与 SiLU 激活函数组成，以弥补由于 SSM 的顺序约束而丢失的内容；两个分支的输出将被拼接，并通过最终的线性层进行投影。这种协同设计确保了最终的特征表示能够同时结合顺序信息和空间信息，从而利用两个分支的优势。

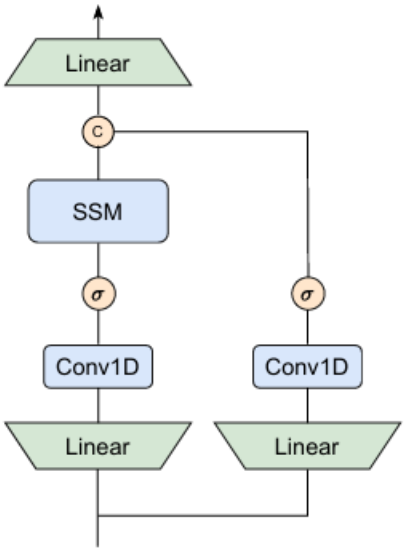

图 6: 融合状态空间模型与卷积的特征提取结构示意图

每个分支的输出将被投影到大小为 $\frac{C}{2}$ 的嵌入空间（即原始嵌入维度的一半），以保持与原始块设计相似的参数数量。给定输入 X_{in} ，MambaVision 混合器的输出 X_{out} 计算如下：

$$
\begin{aligned}
X_1 &= \text{Scan}\left(\sigma\left(\text{Conv}\left(\text{Linear}(C, \tfrac{C}{2})(X_{\text{in}})\right)\right)\right), \\
X_2 &= \sigma\left(\text{Conv}\left(\text{Linear}(C, \tfrac{C}{2})(X_{\text{in}})\right)\right), \\
X_{\text{out}} &= \text{Linear}\left(\tfrac{C}{2}, C\right)(\text{Concat}(X_1, X_2))
\end{aligned}
$$

其中，$\text{Linear}(C_{\text{in}}, C_{\text{out}})(\cdot)$ 表示具有输入和输出嵌入维度 C_{in} 和 C_{out} 的线性层，Scan 是选择性扫描操作，σ 是激活函数，使用 Sigmoid Linear Unit (SiLU)。此外，Conv 和 Concat 分别表示一维卷积和拼接操作。

2.3.2 基于 TabTransformer 的表格特征编码

传统眼底影像分类系统存在 信息单一化的局限，仅依赖图像像素，忽视患者年龄、病史等关键信息 语义断层。临床研究显示，结合患者属性信息可使糖尿病视网膜病变诊

断准确率得到显著提升，这促使我们探索将表格模态整合到眼底分析系统中。

2.3.2.1 自注意力机制

自注意力机制[19]通过键值查询动态计算特征间关联权重，突破传统模型的局部感知限制，单层即可实现全局上下文建模。其核心优势在于并行化计算特征交互矩阵，结合多头机制分治不同语义空间的关联模式，在避免循环或卷积结构的同时，高效捕获长距离依赖关系。

自注意力机制通过计算以下三个向量来捕捉序列中词与词之间的关系：

- 查询（**Query**）：表示当前词语需要寻找什么信息；
- 键（**Key**）：表示其他词语能够提供什么信息；
- 值（**Value**）：表示实际传递的信息内容。

对于输入序列 $X = (x_1, \cdots, x_n)$，通过线性变换可以得到查询、键和值矩阵：

$$Q = XW^Q, \quad K = XW^K, \quad V = XW^V$$

接着计算注意力权重并得到输出：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

其中，d_k 为键向量的维度，缩放因子 $\sqrt{d_k}$ 用于防止点积结果过大导致梯度消失。在此基础上，引入了多头自注意力机制，用以提升模型的表达能力：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(head_1, \ldots, head_h)W^O$$

其中每个注意力头的计算为：

$$head_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

通过多个不同子空间的注意力头并行处理输入信息，多头注意力机制能够更全面地捕捉序列中的依赖关系。

[19]Vaswani, Ashish, et al. ‘Attention Is All You Need’. Advances in Neural Information Processing Systems, edited by I. Guyon et al., vol. 30, Curran Associates, Inc., 2017.

2.3.2.2 表格特征建模

自 Transformer 架构横空出世以来，其凭借在自然语言处理和计算机视觉任务中的卓越表现，已成为现代人工智能的核心技术之一。然而，在处理结构化表格数据时，传统的深度学习方法往往难以匹敌基于树模型（如 XGBoost、LightGBM）的性能。这一矛盾催生了一个关键问题：能否将 Transformer 的优势引入表格数据建模？在此背景下，TabTransformer[20]应运而生。

(1) 基于上下文的特征嵌入

传统方法中，类别型特征通过静态嵌入映射为固定向量，而 TabTransformer 引入 Transformer 编码器，利用自注意力机制动态学习特征嵌入的上下文关系。例如，在电商场景中，“用户年龄”和“商品价格”两个特征的交互权重会根据其他特征（如“购买历史”）动态调整，从而捕捉更灵活的特征交互。

(2) 特征间自注意力建模

TabTransformer 对每个样本的所有特征嵌入进行自注意力计算，自动识别哪些特征组合对预测目标更重要。例如，在医疗诊断中，“血糖水平”与“BMI 指数”的交互可能比“性别”与“职业”的交互更具信息量，模型会自动赋予前者更高权重。

(3) 与数值型特征的高效融合

数值型特征通过标准化后直接输入模型，与经过 Transformer 处理的类别型特征嵌入拼接，最终通过全连接层输出预测结果。这种设计既保留了数值特征的原始信息，又通过注意力机制增强了类别特征的表达能力。

2.3.3 基于 MLP 的多模态融合方法

对于先前得到的图像编码 $V \in \mathbb{R}^N$ 与表格编码 $T \in \mathbb{R}^{H\times W\times 3}$，我们将使用上文中提到过的多头自注意力机制进行跨模态间的映射对齐：

$$\mathrm{Attn}_V = \mathrm{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V$$

对表格模态进行同样的操作，得到 Attn_T。其后在模态融合阶段，为降低计算的复杂度，我们采用了较为简单的方法，将向量直接相加：

$$F_{\text{fused}} = \mathrm{Attn}_V + \mathrm{Attn}_T$$

在具体实现中，可以加入可学习的缩放因子，以增强模型的表达能力：

[20]Huang, Xin et al. “TabTransformer: Tabular Data Modeling Using Contextual Embeddings.” ArXiv abs/2012.06678 (2020): n. pag.

$$F_{\text{fused}} = \alpha \cdot \text{Attn}_V + \beta \cdot \text{Attn}_T$$

将得到的融合向量 F_{fused} 输入至多层全连接神经网络中，最终输出为八分类的概率分布。

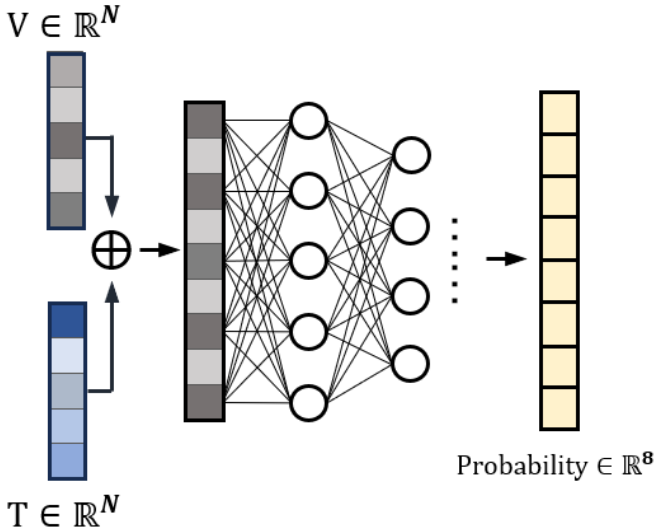

图 7: 基于 MLP 的多模态融合方法示意图

2.4 智能眼底诊断平台设计与实现

传统眼底诊断高度依赖医疗资源分布与医师经验积累，在基层医疗机构与偏远地区存在诊断滞后、误诊率高等系统性难题。为此，我们在深度学习模型的基础上构建了智能化的眼底诊断平台，平台基于前后端协同架构，突破传统单机版软件的时空限制，为基层医生或患者提供优秀的辅助诊断工具。

前端模块基于工程化框架开发，以提升医疗数据管理效率与可视化分析为核心目标。通过患者基本信息录入与眼底影像上传组件，支持 JPG、PNG 等常见格式的批量上传与云端同步，确保数据采集流程标准化。

后端采用轻量级 Flask 框架，确保医疗数据处理的稳定性与可维护性，主要包括三个核心模块：高效影像处理管道，通过 Flask 的多进程工作模式实现左右眼底图像的并行预处理；数据通信保障，借助 Flask-CORS 精细化配置跨域策略，支持医院内网与互联网的混合部署；可追溯运维体系，通过分级日志系统记录操作链路，确保从影像接收至模型预测的全过程可追溯。

该系统支持以下功能：

1. 患者信息管理：录入患者年龄、性别等基本信息，补充临床观察关键词。

2. 影像上传：支持同时上传左右眼的高清眼底照片（JPG/PNG 格式）或批量上传，自动进行图像质量校验。

3. 深度学习辅助诊断：后端机器学习模型分析影像特征，生成糖尿病视网膜病变等 8 类疾病的概率预测。

4. 结果可视化：前端以柱状图展示各疾病概率。

图 8: 疾病诊断上传信息页面

图 9: 疾病诊断结果页面

2.5 实验与分析

本团队在实验时，对于给定与补充的数据集，按照 8:2 的比率随机划分为训练集与验证集。为训练 MambaFusion 模型，本团队使用了 AdamW 优化器，并设定了 1e-4 的初始学习率，该学习率会随着训练过程中动态调整。实验训练了总计 10 个 epochs，以达到最佳性能而不至于过拟合。

2.5.1 对比模型

为证明模型的有效性，本团队对几个有竞争力的基础模型进行了对比实验：

（1）SENet[21]

（1）Vgg19

（2）ResNet50

（3）EffcientNetB3[22]

本团队将通过进行对比实验证明提出的 MambaFusion 模型的有效性。在实验中我们采取了精确率作为衡量的指标。

2.5.2 指标分析

本项目选择使用精确率（Precision）作为实验的评判标准。这一指标的选择基于医学影像诊断任务的特殊性，将健康样本误判为患病（FP）可能导致过度医疗（如不必要的

[21]Lu Z, Miao J, Dong J, Zhu S, Wu P, Wang X, Feng J. Automatic Multilabel Classification of Multiple Fundus Diseases Based on Convolutional Neural Network With Squeeze-and-Excitation Attention. Transl Vis Sci Technol. 2023 Jan 3;12(1):22. doi: 10.1167/tvst.12.1.22. PMID: 36662513; PMCID: PMC9872849.

[22]WangJ, Yang L, HuoZ,HeW,LuoJ.Multi-label classification of fundus images with EfficientNet.IEEE Access. 2020;8: 212499–212508.

治疗或检查），对患者和医疗资源造成负担，精确率直接衡量模型预测为某类时的可靠性，可以减少误诊风险。而具体到所使用的数据集时，我们注意到其中某些疾病类别样本极少，多数类（如正常眼底）占主导，如若选择准确率作为指标，则会被多数类的正确预测主导，掩盖模型在少数类上的性能缺陷。

针对每一类病症，精确率的计算公式如以下所示：

$$\text{Precision}_i = \frac{\text{TP}_i}{\text{TP}_i + \text{FP}_i}$$

其中，TP_i 为正确预测为类别 i 的样本数，FP_i 为其他类别样本被错误预测为类别 i 的数量。

在以精确率为主要指标之外，我们同样在一定程度上参考了召回率（Recall），该指标的核心思想为宁可误诊、不可漏诊，与精确率通常为负相关，不过仍存在一定的参考价值：

$$\text{Recall}_i = \frac{\text{TP}_i}{\text{TP}_i + \text{FN}_i}$$

其中，FN_i 为真实为类别 i 但被错误预测为其他类别的样本数。

2.5.3 结果分析

由下表 2 中数据可知，对比前人的研究结果，本团队设计的 MambaFusion 模型在精度上提高了约 10%，且运行所需显存也得到了显著优化，平均每个 Epoch 训练的耗时对比 ViT（VisionTransformer）减少近一倍，由 16min 降低至 8m。

表 2: Precision and Recall for Different Models

Model	Precision	Recall
SENet	0.54	0.47
Vgg19	0.70	0.57
ResNet50	0.65	0.66
EfficientNetB3	0.71	0.66
MambaFusion	0.79	0.77

在本章节，本团队构建了基于状态空间模型与多模态的 MambaFusion 模型，使得其在精确率指标、计算速度上都获得了最佳的性能，证明该方法可以有效的提高医学影像诊断的效率与效果。

第三章　项目管理与人员架构

3.1　人员架构

人员架构如表 3 所示

表 3: 人员架构

姓名	角色	职责
邱炜众	项目经理	1. 分析赛题需求并设计解决方案; 2. 统筹项目进度安排; 3. 训练与优化模型结构; 4. 负责后端 API 的设计; 5. 负责技术文档的编写。
董新心	产品经理	1. 检索并整理相关领域前沿语与经典论文; 2. 寻找可供参考的代码与博客; 3. 负责除技术外文档的编写。
金惠检	算法工程师	1. 训练与优化模型; 2. 技术文档的编写。
阮虹涛	算法工程师	1. 训练与优化模型; 2. 技术文档的编写。
叶雄志	全栈工程师	1. 负责前端平台的设计与搭建; 2. 负责后端 API 的调试与接入。

3.2　任务分配与进度安排

任务分配与进度安排将从时间段、主要任务与工作成果方面来展示，具体的任务安排进度表如表 4 所示。

表 4: 项目任务分解与进度安排表

时间段	主要任务	工作成果
2.6-2.14	资料检索	1. 相关领域论文调研 2. 基础知识学习

时间段	主要任务	工作成果
2.15-2.21	可行性分析与需求分析	1. 可行性分析报告 2. 需求分析报告 3. 项目管理计划 4. 团队分工
2.22-3.1	技术准备与概要设计	1. 团队编码规范说明 2. 关键技术选型 3. 数据集预处理
3.2-3.9	详细设计	1. 项目开发详细计划 2. 模型选择与实验
3.10-3.14	系统编码	1. 模型选择与实验 2. 前端平台设计
3.15-3.21	系统编码与功能集成	1. 模型训练与实现优化 2. 后端模块编写与对接 3. 项目文档撰写
3.22-3.31	系统测试	1. 功能测试 2. 集成测试
4.1-4.7	系统修正	1. 源代码优化并将其应用在测试集 2. 所需资料定稿

3.2.1 项目生命周期与组织

(1) 项目生命周期

在项目的开发过程中，首先由项目负责人根据赛题需求组建开发团队，并初步制定项目目标与方向，正式进入项目生命周期的启动阶段。在此阶段，团队成员通过检索文献和学习基础知识，对相关领域进行深入了解，为后续开发打下理论基础。紧接着，项目组对项目的可行性进行全面分析，从技术、操作、经济等多个维度评估项目的实施前景，同时完成需求分析报告、项目管理计划和团队分工等内容，确保项目具备清晰的目标与合理的组织结构。

随后进入规划与设计阶段，团队围绕技术选型、编码规范及数据处理等关键内容展开准备工作，并制定详细的开发计划。概要设计与详细设计紧密衔接，在明确功能模块和项目结构的基础上，逐步细化模型选择与实验方案，为后续系统实现打好基础。

进入执行阶段后，团队开始系统编码与功能集成，分别开展前端平台设计、模型训练优化以及后端模块的编写与接口对接等任务。同时，也同步推进项目文档的编写工作。系统初步完成后，项目组对其进行功能测试与集成测试，确保系统性能与功能稳定。根据测试反馈，团队在最后阶段对源代码进行优化，并在测试集中验证其效果，同时完成相关文档的最终定稿，顺利完成项目的收尾工作。

通过以上各阶段的紧密衔接与高效执行，项目得以有序推进，最终实现既定目标，确保成果的交付质量与实际应用价值。

(2) 项目组织

在项目启动阶段，团队首先明确了整体项目的开发目标与核心任务，并在此基础上开展前期的调研与学习工作，确保全员对项目背景与方向形成统一认识。

随后，项目组根据前期分析结果，结合实际开发需求，对任务进行了合理划分，并依据每位成员的能力特长，如技术开发、模型优化、需求分析或前后端实现等，进行岗位职责的分配，确保每项工作均有明确责任人。

同时，项目组制定了人员管理与沟通机制，明确各阶段的协作方式与反馈流程，为后续项目的有序推进提供了组织保障。在项目整个开发周期内，团队保持紧密协作，确保开发过程的高效与成果的质量。

3.2.2 项目过程管理与质量评估

（1）项目初期组建团队，明确项目方向与目标任务。

（2）按照项目生命周期有序推进各阶段工作。

（3）建立管理制度，实行每周例会制度，保障问题及时沟通与解决。

（4）项目负责人全程监督进度，确保各任务按计划执行。

（5）为各阶段设定明确时间节点，推动项目在正确节奏下进行。

（6）根据实际需求动态调整开发内容，及时修正偏差，确保项目质量与目标一致。

3.2.3 项目风险分析

在项目启动阶段，经项目成员商定及认可，确立了项目风险与其应对措施来合理科学的控制项目开展过程中的风险。具体的风险与策略如表 5 所示。

表 5: 风险评估以及应对措施

风险项	影响度	等级	应对措施
相关知识储备不足	50%	3	先进行概念性的知识学习，再进行项目的开展
人员沟通不力	60%	2	确立每周一次例会制度，及时汇报，及时沟通
工作进度延迟	40%	3	重新安排工作任务时间表，及时调整
项目进行方向出现错误	80%	1	仔细进行分析工作，及时评审，及时调整
预算与资源不足	20%	4	设定最优的资源分配方案，及时向上级申请

3.2.4 项目评审

在项目开发的过程中，为保证项目的合理有序进行，在各个阶段均进行评审工作，以保证系统的正确方向与高质量。具体的评审记录如表 6 所示。

表 6: 项目评审安排

评审内容	评审时间	评审人员
项目需求分析与方向确定	2025.2.21	项目负责人与指导老师
资料的收集与模型的大致确立	2025.3.9	项目负责人与指导老师
项目的概要设计	2025.3.14	项目负责人与指导老师
模型的细化设计	2025.3.21	项目负责人与指导老师
系统功能	2025.4.5	项目负责人与指导老师

第四章　可行性分析

4.1 经济可行性

本项目采用轻量化模型架构与开源技术栈，在成本控制与资源利用方面具备显著优势，基于 PyTorch 框架与公开眼底数据集构建模型，通过 MambaVision 的状态空间模型将推理显存需求降低 37%，单次预测能耗较传统 Transformer 模型减少 52%，适配普通 GPU 服务器即可部署；诊断平台采用 Next.js+Flask 轻量级架构，单服务器可支持日均 10 万次查询，硬件投入成本较同类医疗 AI 系统降低 60% 以上。

本团队开发所需的成本仅为需要的基础设备和资料支出，设备精简，成本低，而项目本身由于上述的原因具有巨大经济效益，足够维持本项目的运作。由此经济可行。

4.2 社会可行性

近年来，人工智能一直是我国乃至全世界的热潮，深度学习也由此被引入医疗领域，使得医学影像分析技术能更贴合于疾病筛查与辅助诊断的目标。计算机视觉领域作为深度学习中的重要方向，随着技术的不断发展，眼底疾病识别算法在越来越多的医学应用中产生融合与突破，如糖尿病视网膜病变筛查、老年黄斑变性诊断等，其诊断效能和速度也不断得到提升。眼底疾病的智能诊断技术正是医学影像 AI 中的一个重要研究课题，被广泛应用于各级医疗机构。

随着医疗需求不断增长，基层医疗机构对眼底疾病筛查的需求也在持续增加。眼底疾病智能诊断算法作为眼科 AI 应用的核心部分，是推动传统眼底病筛查模式创新和提高诊断效率的关键。当前，社会急需高效、轻量化、符合医疗标准的眼底疾病识别方法，以提高诊断准确率并减少失盲风险。由此社会可行。

4.3 政策可行性

眼底疾病智能识别是人工智能在医疗健康领域应用中的重要方向，是连接智能医疗基础设施与疾病筛查场景的关键技术之一。随着人工智能技术与智慧医疗系统的不断融合，中国在眼底影像辅助诊断方面的技术能力持续提升，市场需求也呈现稳步增长态势。目前，眼底智能识别技术已成为我国 AI 医学图像分析领域较为成熟的应用方向之一，在多项国家级政策支持下（表 7），该技术正加速在基层筛查、远程医疗与公共卫生等多个医疗场景中的推广应用。

表 7: 近 10 年我国人工智能医疗影像及智能诊断相关政策

发布时间	政策名称	发布机构	主要内容
2016 年 10 月	《“健康中国 2030”规划纲要》	中共中央国务院	加强新一代信息技术与健康医疗融合，推进智能诊断、远程医疗等服务模式建设。
2017 年 7 月	《新一代人工智能发展规划》	国务院	将医疗健康列为人工智能重点领域，支持 AI 在医学图像识别、智能诊断中的应用。
2019 年 7 月	《国务院关于实施健康中国行动的意见》	国务院	强调慢性病早筛早诊，推动智能筛查技术在基层普及。

2020 年 11 月	《关于促进“互联网 + 医疗健康”发展的意见》	国家卫健委	鼓励基层采用人工智能影像识别系统，缩短诊疗周期，提升诊断能力。
2021 年 8 月	《“十四五”国家健康信息化规划》	国家卫健委、工信部等	推进 AI 辅助诊断系统规范化发展，建设智能诊疗体系。
2022 年 3 月	《“十四五”全国眼健康规划(2021—2025年)》	国家卫健委等六部委	建设国家眼底疾病智能筛查平台，推动 AI 在慢病管理中的应用。
2023 年 6 月	《智能医疗装备创新发展实施方案》	工业和信息化部等	支持智能医学影像装备研制，推动 AI 在眼科筛查中的临床应用。

4.4 人员可行性

指导老师：本项目指导老师在深度领域具有丰富经验与多年的教学及实验经验，曾多次带队参加挑战杯、大学生创新创业、互联网 + 大赛等重要大型赛事，并且所带的团队中有多支队伍获得国家级一级奖、省部级一等奖等奖项，技术与理论基础扎实。

团队成员：团队成员在深度学习与人工智能领域均有较为深厚的知识积累与学习热情，并对该方向均有深入定向研究。根据本赛题，本团队设计的分工合理，安排得当。虽然项目建设期只有几个月，工作量较大，算法与性能方面的优化空间大，但团队负责人安排良好，团队成员协调有序，本团队有信心有能力在比赛的要求和限定时间内完成项目。由此本项目人员可行。

4.5 法律可行性

我们团队所搭建与设计的算法模型完全遵守国家及国际发布的法律法规法规，严格遵照中国颁布的《中华人民共和国著作权》与《计算机软件保护条例》中的内容，绝无任何侵权行为。本团队坚守法律及道德底线，避免一切造成法律纠纷的隐患。由此法律可行。

第五章　结语